

ORCA

Observatorio de Riesgo en Contratación de Antioquia · v1.0

Proyecto final · Primera entrega parcial

Estrategia, procesos, datos abiertos y boceto de arquitectura

Data Office Strategy · Universidad Pontificia Bolivariana · Docente: María Victoria Valencia Arango

Equipo: Luis Ángel Seoanes Ovieso · *Integrante 2* · *Integrante 3*

28 de septiembre de 2026

Contenido: 01 Problema, estrategia y Data Office · 02 Selección de datos abiertos · 03 Procesos BPMN · 04 Arquitectura ArchiMate

01 · Problema, estrategia y diseño del Data Office

Solución	ORCA — Observatorio de Riesgo en Contratación de Antioquia
Versión	1.0 (Entrega 1) · 28 de septiembre de 2026
Asignatura	Data Office Strategy · UPB · Docente: María Victoria Valencia Arango
Criterio de rúbrica	1. Problema, estrategia y diseño organizacional (10 %)

Nota sobre el caso. El caso es un escenario académico: una contraloría territorial (inspirada en la Contraloría General de Antioquia) que crea un Data Office. **Todas las cifras vienen de datos abiertos reales**, consultados el 27-sep-2026 con la API de [datos.gov.co](#) y reproducibles en [notebooks/00_perfilamiento_fuente.ipynb](#). Los procesos internos de la entidad (AS-IS) son una reconstrucción razonada a partir de la normativa de control fiscal. No son información interna de ninguna entidad.

1. Contexto

Las contralorías vigilan cómo las entidades públicas gastan los recursos. La mayor parte de ese gasto pasa por la **contratación pública**, que desde 2019 se publica casi en su totalidad en **SECOP II** y se expone como dato abierto, con actualización diaria, en [datos.gov.co](#).

El dato existe, es público y está fresco. Lo que falta es la **capacidad organizacional** para convertirlo en decisiones de vigilancia. Esa capacidad es la que construye un Data Office.

2. El problema, medido

Entidades con sede en Antioquia, contratos firmados entre el 1-ene-2024 y el 27-sep-2026 (SECOP II):

Indicador	Valor	Lectura
Contratos firmados	302.507	≈ 110.000 contratos por año: nadie puede revisarlos uno a uno
Valor total contratado	\$56,4 billones COP	—
Entidades contratantes	565	—

Indicador	Valor	Lectura
Proveedores distintos	83.932	—
Contratos por contratación directa	85,5 %	La modalidad con menor competencia es la regla, no la excepción
Contratos con personas naturales (cédula)	81,5 %	El dataset está lleno de datos personales (PII)
Contratos del orden territorial	187.059 (61,8 %), con el 81,3 % del valor	Es el universo de vigilancia de una contraloría territorial

Señal de riesgo encontrada en los datos: el efecto "Ley de Garantías". La Ley 996 de 2005 restringe la contratación directa en los cuatro meses previos a la elección presidencial (primera vuelta: 31-may-2026):

Mes	Contratos firmados	% contratación directa
dic-2025	3.883	40,9 %
ene-2026	49.906	93,8 %
feb-2026	1.382	14,4 %
mar-2026	1.741	11,5 %
abr-2026	1.403	15,4 %
may-2026	1.391	10,8 %
jul-2026	16.169	89,1 %

En **un solo mes** se firmó el 16 % de todo lo contratado en casi tres años. Firmar en bloque justo antes de una restricción legal no es ilegal por sí mismo. Sí es un patrón que la literatura de integridad en compras públicas (Open Contracting Partnership, *Red Flags for Integrity*) trata como **bandera roja de planeación**: vale la pena vigilar esos contratos primero. Hoy la contraloría no tiene cómo detectarlo de forma sistemática.

La calidad del dato también es parte del problema (detalle en [02](#)): 40.638 contratos de Antioquia sin fecha de firma, 20.706 con ciudad "No Definido", 2.848 con valor \$0, campos de datos personales rellenos con textos como "No definido" o "Sin Descripcion" (nulos disfrazados) y nombres de entidad inconsistentes (p. ej. MUNICIPIO DE ENVIGADO*). Si se analizan tal cual, las conclusiones serán erróneas.

Planteamiento del problema

La contraloría selecciona qué contratos vigilar **por criterio histórico y juicio experto**, sobre extracciones manuales del SECOP que no se validan, no se trazan y copian datos personales sin control. Con ≈ 110.000 contratos al año en Antioquia y 85,5 % adjudicados sin competencia, **la cobertura es baja, la selección no**

es explicable y los patrones de riesgo (como el pico pre-Ley de Garantías) pasan inadvertidos.

3. Necesidad de negocio

Pasar de una vigilancia fiscal reactiva y por muestreo a una priorización continua basada en riesgo, sobre datos confiables, trazables y que protejan a los titulares de datos personales.

Preguntas de negocio que ORCA debe responder (guían el EDA de la entrega 2 y el dashboard de la final):

#	Pregunta	Decisión que habilita
P1	¿Qué entidades concentran contratación directa por encima de su comportamiento histórico?	Incluir la entidad en el Plan de Vigilancia (PVCF)
P2	¿Qué contratos se firmaron en ventanas atípicas (pre-Ley de Garantías, fin de vigencia)?	Priorizar revisión documental
P3	¿Qué proveedores concentran contratos o valor en una misma entidad?	Auditoría de cumplimiento al par entidad–proveedor
P4	¿Qué personas naturales tienen contratos simultáneos con varias entidades?	Verificar capacidad real de ejecución
P5	¿Qué contratos tienen valores atípicos para su tipo y modalidad?	Revisión de estudios de mercado
P6	¿Qué procesos "competitivos" tuvieron un único oferente?	Alerta temprana por posible direccionamiento

4. Objetivos (SMART, horizonte del proyecto)

#	Objetivo	Meta medible	Fecha
O1	Automatizar la ingesta de SECOP II	100 % de los contratos de Antioquia desde 2024 cargados por API, con linaje por lote	23-oct-2026
O2	Medir la calidad del dato	6 dimensiones medidas por lote en el notebook; umbral de publicación $\geq$ 95 %	23-oct-2026
O3	Proteger los datos personales	0 campos PII en claro en las capas de consumo (dashboard y data mart)	13-nov-2026
O4	Priorizar por riesgo	Score de riesgo con $\geq$ 6 banderas rojas para el 100 % de los contratos del alcance	13-nov-2026
O5	Institucionalizar el gobierno del dato	Plan de Gobierno de Datos con los 8 artefactos exigidos, aplicado al dataset	13-nov-2026

5. Estrategia

5.1 Alineación estratégica

Nivel	Contenido para ORCA
Estrategia corporativa (misional)	Control fiscal oportuno y preventivo, en línea con el Acto Legislativo 04 de 2019 y el Decreto 403 de 2020 (vigilancia y seguimiento permanente de los recursos públicos).
Estrategia de negocio (del área de vigilancia)	Mayor cobertura con la misma planta de auditores, priorizando por riesgo en lugar de muestrear.
Estrategia funcional de datos (el Data Office)	Tratar el dato de contratación como activo gobernado : una sola fuente confiable, trazable y segura que alimenta la priorización. Se apoya en la Política Nacional de Explotación de Datos (CONPES 3920 de 2018).

5.2 Tipo de estrategia de datos: defensa primero, ataque sobre esa base

Se usa el marco de **Dallemule y Davenport (HBR, 2017), *What's your data strategy?***, que distingue una estrategia **defensiva** (cumplimiento, calidad, seguridad, una sola versión de la verdad) de una **ofensiva** (analítica que genera valor y decisiones).

Defensa		Ataque
En ORCA	Calidad medida por lote, seudonimización de PII (Ley 1581), linaje, control de acceso, catálogo	Score de riesgo, banderas rojas, alertas tempranas, dashboard de priorización
Peso inicial	≈ 60 %	≈ 40 %

Por qué este balance:

1. **Una contraloría no puede equivocarse con los datos.** Un hallazgo fiscal basado en un dato erróneo (un valor de \$1,16 billones mal digitado, una fecha nula) se cae, y le cuesta credibilidad a la entidad. La calidad es condición de la analítica, no un complemento.
2. **El dataset está lleno de PII** (81,5 % de contratos con personas naturales, cédulas de supervisores y ordenadores del gasto). Que un dato sea público por transparencia (Ley 1712 de 2014) no autoriza cualquier tratamiento posterior (Ley 1581 de 2012, principio de finalidad). Tomar la defensa a la ligera expone a la entidad.
3. **El ataque produce el valor visible** (qué auditar primero) y es lo que justifica ante el Contralor la inversión en el Data Office. Sin ataque, la defensa se percibe como burocracia.

Con más madurez, la proporción se desplaza hacia el ataque: modelos predictivos y cruces con otras fuentes (ver §8).

5.3 DOFA

Fortalezas	Debilidades
Fuente abierta, oficial, diaria y con API · Conocimiento experto de los auditores · Mandato legal claro	Procesos manuales en Excel · Dependencia de TIC para extracciones · Sin roles de datos definidos · Sin reglas de calidad
Oportunidades	Amenazas
CONPES 3920 y lineamientos de gobierno digital · Herramientas gratuitas (Python, GitHub, Power BI) · Patrones de riesgo detectables (Ley de Garantías)	Cambios de esquema en SECOP sin aviso · Riesgo legal por mal uso de PII · Resistencia cultural ("siempre se ha auditado así") · Falsos positivos que desgasten a los auditores


5.4 Propuesta de valor por actor

Actor	Hoy	Con ORCA
Contralor(a)	Plan de vigilancia difícil de justificar	Plan priorizado por riesgo, explicable y trazable
Auditor	Días buscando y depurando datos	Recibe alertas priorizadas con la evidencia enlazada
Ciudadanía	Ve resultados tardíos	Vigilancia más oportuna sobre el gasto de su municipio
Titulares de datos (contratistas)	Cédulas copiadas en archivos sueltos	Datos seudonimizados y con acceso controlado

5.5 Principios del Data Office

1. **Calidad antes de publicar:** ningún lote llega al dashboard sin score de calidad (quality gate).
2. **Privacidad desde el diseño:** la PII se seudonimiza en la capa *curated*, antes de cualquier consumo.
3. **La máquina mide, la persona decide:** el score prioriza, pero cada actuación fiscal la decide un rol con nombre propio.
4. **Todo dato tiene dueño:** cada activo del catálogo tiene un Data Owner y un Data Steward.
5. **Trazable de extremo a extremo:** del registro en el dashboard se puede volver al lote, a la consulta SoQL y al contrato original en SECOP.

5.6 Hoja de ruta



5.7 Indicadores de éxito del Data Office

KPI	Fórmula	Meta
Frescura	Horas entre el corte de SECOP y la publicación en el dashboard	≤ 24 h
Calidad por lote	Score ponderado de las 6 dimensiones	≥ 95 %
Cobertura de riesgo	Contratos con score / contratos del alcance	100 %
Precisión de alertas	Alertas pertinentes / alertas gestionadas (lo registra el auditor)	≥ 60 % en el primer trimestre
Protección de PII	Campos PII en claro en capas de consumo	0
Gobierno	Activos del catálogo con Owner y Steward asignados	100 %

6. Diseño organizacional del Data Office

6.1 ¿Qué modelo organizacional?

Modelo	Ventaja	Desventaja para una contraloría
Centralizado (todo en una oficina de datos)	Estándares únicos, control fuerte	Cuello de botella; la oficina no conoce el negocio de cada sector auditado
Descentralizado (cada dirección hace lo suyo)	Cercanía al negocio	Diez versiones del mismo contrato, sin estándares ni control de PII: justo el AS-IS actual
Híbrido / federado (hub & spoke) ✓	Estándares, plataforma y gobierno centrales; conocimiento de negocio distribuido	Exige coordinación (comité) y roles bien definidos

Decisión: modelo híbrido *hub & spoke*.


- El **hub** (Data Office central) es dueño de lo que debe ser único: la plataforma, el pipeline, las reglas de calidad, la política de PII, el catálogo y el linaje.
- Los **spokes** (las Contralorías Auxiliares sectoriales: salud, educación, infraestructura, etc.) aportan lo que solo ellos saben: qué es riesgoso en su sector, si una alerta es pertinente, qué actuación procede.
- Así el Data Office **no se vuelve el dueño del negocio**: el dato es de quien responde por él (el Data Owner), y el Data Office pone las reglas y la plataforma.

6.2 ¿Dónde se ubica el CDO?

El **CDO reporta directamente al Despacho del Contralor(a)**, no a la Oficina TIC:

- El problema es de **decisión y gobierno** (qué vigilar, con qué dato, bajo qué reglas), no de infraestructura.
- Bajo TIC, el gobierno del dato se reduce a "administrar bases de datos" y pierde autoridad sobre los dueños del negocio.
- TIC sigue siendo clave como **custodio técnico** de la infraestructura y la seguridad.

6.3 Organigrama



6.4 Roles y responsabilidades

Rol	Ubicación	Responsabilidades clave	Dominio DAMA-DMBOK
CDO	Hub, reporta al Despacho	Estrategia de datos, prioridades, presupuesto, rinde cuentas por el valor del Data Office	Gobierno de datos
Comité de Gobierno de Datos	Transversal	Aprueba políticas, umbrales de calidad y reglas de riesgo; resuelve conflictos entre direcciones	Gobierno de datos
Líder de Gobierno de Datos	Hub	Catálogo, diccionario, políticas, métricas de calidad, gestión de metadatos	Metadatos · Calidad
Data Owner	Spoke (Contralor Auxiliar)	Responde por el uso del dato en su sector; aprueba accesos; decide la actuación fiscal	Gobierno de datos · Seguridad
Data Steward de negocio	Spoke (auditor referente)	Define reglas de negocio y de riesgo del sector; revisa incidentes de calidad; recalibra con los falsos positivos	Calidad · Gobierno
Ingeniero(a) de Datos	Hub	Pipeline de ingesta, limpieza y normalización; linaje; automatización	Integración · Almacenamiento
Analista / Científico(a) de Datos	Hub	EDA, banderas rojas, score de riesgo, dashboard	BI · Analítica
Custodio técnico (TIC)	Oficina TIC	Infraestructura, copias de seguridad, gestión de identidades y accesos	Seguridad · Operaciones
Oficial de Protección de Datos Personales	Asesor del Comité	Verifica cumplimiento de la Ley 1581 (finalidad, circulación restringida, seguridad) y aprueba la política de seudonimización	Seguridad
Consumidor (auditor)	Spoke	Usa alertas y tablero; registra si la alerta fue pertinente	—

6.5 RACI preliminar (se completa en el Plan de Gobierno, Entrega 2)

R = Responsable (ejecuta) · A = Aprueba (rinde cuentas) · C = Consultado · I = Informado

Actividad	CDO	Comité	Líder Gob.	Owner	Steward	Ingeniería	Analítica	TIC	Oficial PD	Auditor
Definir la estrategia y las prioridades del Data Office	A	C	C	C	I	I	I	I	I	I
Aprobar políticas y estándares	C	A	R	C	C	I	I	C	C	I
Ingesta diaria desde la API	I	—	I	I	I	A/R	I	C	—	—
Definir las reglas de calidad	I	A	R	C	R	C	C	—	—	I
Resolver incidentes de calidad	I	—	C	I	A/R	R	I	—	—	—
Seudonimizar y clasificar la PII	I	A	C	C	I	R	I	C	C	—
Definir las banderas rojas de riesgo	I	A	C	C	R	C	R	—	—	C
Aprobar el acceso a datos del sector	I	—	C	A	C	I	I	R	C	I
Gestionar alertas de riesgo	—	—	—	I	I	—	I	—	—	A/R
Decidir la actuación fiscal	I	—	—	A/R	C	—	C	—	—	C

6.6 Forma de trabajo: agilidad dentro de la estructura

La **estructura** es funcional e híbrida (quién responde por qué). La **ejecución** es ágil:

- **Célula ORCA** (squad multidisciplinario): Product Owner (delegado del Data Owner), Líder de Gobierno, Ingeniero(a) de Datos, Analista y un Data Steward de negocio rotativo.
- **Scrum con sprints de 2 semanas**, alineados a las entregas: Sprint 1 (fundación), Sprints 2–3 (pipeline y gobierno), Sprints 4–5 (riesgo y dashboard).
- **Backlog** en GitHub Projects/Issues: cada historia de usuario se enlaza a su commit, y así el propio repositorio sirve como evidencia de trazabilidad.
- **Definición de "terminado"** que incluye gobierno: una historia no se cierra si el activo que produce no está en el catálogo con Owner, Steward y clasificación.

6.7 Roles del equipo del proyecto

Integrante	Rol en ORCA	Entregables que lidera
Luis Ángel Seoanes Ovieso	CDO / Arquitecto(a) de datos · Product Owner	Estrategia, ArchiMate, integración y README
Integrante 2	Líder de Gobierno de Datos · Data Steward	Plan de Gobierno, reglas de calidad, clasificación y RACI

Integrante	Rol en ORCA	Entregables que lidera
Integrante 3	Ingeniero(a) de Datos · Analista	Pipeline Python, EDA, automatización y dashboard

Los tres integrantes hacen commits en todos los componentes. Los roles indican quién lidera cada frente, no quién lo hace solo.

6.8 Madurez

Dimensión	Hoy (AS-IS)	Meta con ORCA
Gobierno	Nivel 1 · Inicial: sin roles ni políticas	Nivel 3 · Definido: roles, políticas y comité operando
Calidad	Nivel 1: se corrige a mano cuando se nota	Nivel 3: reglas medidas por lote con umbral
Metadatos y linaje	Nivel 1: no existen	Nivel 3: catálogo y linaje por lote
Analítica	Nivel 1–2: consultas ad hoc	Nivel 3: score de riesgo y tablero recurrente

7. Riesgos y supuestos

Riesgo / supuesto	Mitigación
SECOB cambia columnas o nombres sin aviso	Validación de esquema en cada lote (regla de <i>validez</i>); el lote falla de forma controlada y se registra en el linaje
La API pública es lenta o se cae	Reintentos con espera (backoff), ingesta incremental y límites de página (ver el BPMN TO-BE)
Las banderas rojas generan falsos positivos	Retroalimentación del auditor → el Steward recalibra (mejora M6 del BPMN)
Uso indebido de la PII	Seudonimización en <i>curated</i> , acceso por rol y aprobación del Oficial de Protección de Datos
Supuesto: el alcance de vigilancia son las entidades del orden territorial de Antioquia	La lista oficial de sujetos de control, que excluye municipios con contraloría propia, se incorporará como dato maestro en la entrega 2

8. Evolución con mayor madurez

- 1. Cruces con otras fuentes abiertas (sanciones y multas, RUES, presupuesto territorial) para enriquecer el riesgo.
- 2. Pasar de reglas a **modelos** (detección de anomalías), entrenados con los falsos positivos etiquetados.
- 3. Publicar indicadores agregados (sin PII) para la ciudadanía como dato abierto de segunda generación.

Referencias

- Dallemule, L. y Davenport, T. (2017). *What's your data strategy?* Harvard Business Review, 95(3).
- DAMA International (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (2.^a ed.).
- Open Contracting Partnership (2016). *Red Flags for Integrity: Giving the green light to open data solutions*.
- Congreso de Colombia: Ley 1581 de 2012 (protección de datos personales); Ley 1712 de 2014 (transparencia); Ley 996 de 2005 (Ley de Garantías); Acto Legislativo 04 de 2019.
- Presidencia de la República: Decreto 403 de 2020 (control fiscal).
- DNP (2018). CONPES 3920: Política Nacional de Explotación de Datos (Big Data).
- Colombia Compra Eficiente. *SECOP II – Contratos Electrónicos* (jbjy-vk9h), datos.gov.co.

02 · Selección de datos abiertos

Solución	ORCA v1.0 · Entrega 1 · 28-sep-2026
Evidencia reproducible	notebooks/00_perfilamiento_fuente.ipynb (consultas a la API ejecutadas el 27-sep-2026)

1. Criterios de selección

Se buscaron datasets que **sirvan al problema de negocio** y que, además, **permitan demostrar el gobierno del dato**, que pesa el 30 % de la nota. Un dataset "limpio y sin datos personales" facilita el análisis, pero deja poco que gobernar.

Criterio	Peso	Qué se evalúa
C1 · Relevancia para un problema real	25 %	¿Soporta decisiones concretas de una organización?
C2 · Riqueza para el gobierno del dato	25 %	PII que obligue a clasificar, problemas de calidad medibles, varias entidades y relaciones
C3 · Oportunidad (frescura)	15 %	Frecuencia de actualización y fecha del último cargue
C4 · Acceso automatizable	15 %	API estable que permita ingesta programada (automatización)
C5 · Volumen y cobertura	10 %	Suficiente para EDA y patrones; filtrable a un alcance manejable
C6 · Licencia y documentación	10 %	Uso permitido, publicador oficial, metadatos

2. Candidatos evaluados (metadatos verificados vía API de datos.gov.co, 27-sep-2026)

ID	Dataset	Publicador	Filas	Col.	Actualización	Último cargue
jbjy-vk9h	SECOP II – Contratos Electrónicos	Colombia Compra Eficiente	6.070.870	95	Diaria	27-sep-2026
p6dx-8zbt	SECOP II – Procesos de Contratación	Colombia Compra Eficiente	≈ 9,2 M	59	Diaria	26-sep-2026
rpmr-utcd	SECOP Integrado (SECOP I + II)	Colombia Compra Eficiente	≈ 20,8 M	22	Diaria	21-sep-2026
kgxf-xxbe	Resultados únicos Saber 11	ICFES	≈ 7,1 M	51	Semestral	23-ago-2023

Los cuatro tienen licencia **Creative Commons Attribution-ShareAlike 4.0**.

Matriz de decisión (1 = bajo · 5 = alto)

Dataset	C1 (25 %)	C2 (25 %)	C3 (15 %)	C4 (15 %)	C5 (10 %)	C6 (10 %)	Puntaje
SECOP II – Contratos	5	5	5	5	5	5	5,00
SECOP II – Procesos	4	3	5	5	5	5	4,25
SECOP Integrado	4	3	4	5	5	5	4,10
Saber 11	3	4	1	5	5	5	3,65

Por qué se descartan los demás como fuente principal:

- **SECOP Integrado:** agrega SECOP I, pero con solo 22 columnas pierde lo que el gobierno necesita trabajar (supervisores, ordenadores del gasto, fuentes de recursos, días adicionados, estado de ejecución).
- **Saber 11:** tiene PII sensible (fecha de nacimiento, condiciones socioeconómicas), pero su último cargue es de 2023 y cubre 2010–2022. Falla en *oportunidad*, que es una de las 6 dimensiones de calidad exigidas.
- **SECOP II – Procesos** no se descarta: entra como **fuentes complementaria** porque es la que permite medir competencia (número de oferentes).

3. Datasets seleccionados

Código	Dataset	Rol en ORCA	Llave de integración
DS-01	SECOP II – Contratos Electrónicos (jbjy-vk9h)	Principal: hechos de contratación	id_contrato (única)
DS-02	SECOP II – Procesos de Contratación (p6dx-8zbt)	Complementario: competencia (ofertas, proveedores invitados)	DS-01.proceso_de_compra = DS-02.id_del_portafolio
DS-03	DIVIPOLA – Códigos de municipios (gdx- w37w , DANE, 1.122 filas, corte 30-dic-2024)	Dato de referencia (maestro) para normalizar municipios	Nombre normalizado de municipio → código DANE

DS-03 resuelve un problema real de DS-01: la ciudad viene como **texto libre** (con "No Definido" en 20.706 contratos). Tener un maestro de referencia es, en sí mismo, una práctica de gobierno (dominio *Datos maestros y de referencia* de DAMA-DMBOK).

4. Alcance del caso

Filtro	Valor	Justificación
Territorio	departamento = 'Antioquia'	Jurisdicción de la contraloría del caso; contexto regional de la UPB

Filtro	Valor	Justificación
Periodo	fecha_de_firma >= '2024-01-01'	Vigencias recientes (actuaciones oportunas); incluye el ciclo electoral de 2026
Orden	Se conserva todo; se marca orden = 'Territorial' como universo de vigilancia	Nacional (113.333 contratos) y Corporaciones Autónomas (2.115) los vigila la CGR. Se conservan como comparación, fuera del score.

Tamaño del alcance: 302.507 contratos · \$56,4 billones COP · 565 entidades · 83.932 proveedores. Territorial: 187.059 contratos (\$45,8 billones).

5. Estructura de DS-01 (95 campos agrupados)

Grupo	Campos principales	Uso en ORCA
Identificación	id_contrato, referencia_del_contrato, proceso_de_compra, urlproceso	Llave, cruce con DS-02, enlace a la evidencia
Entidad	nombre_entidad, nit_entidad, codigo_entidad, departamento, ciudad, orden, sector, rama	Dimensión entidad; alcance de vigilancia
Contratación	modalidad_de_contratacion, justificacion_modalidad_de, tipo_de_contrato, objeto_del_contrato, codigo_de_categoria_principal	Banderas de modalidad y objeto
Proveedor	tipodocproveedor, documento_proveedor, proveedor_adjudicado, es_pyme, es_grupo	Concentración y simultaneidad (PII si es persona natural)
Fechas	fecha_de_firma, fecha_de_inicio_del_contrato, fecha_de_fin_del_contrato, dias_adicionados	Ventanas atípicas, prórrogas
Valores	valor_del_contrato, valor_pagado, valor_facturado, valor_pendiente_de_ejecucion	Atípicos, ejecución
Fuentes de recursos	sistema_general_de_participaciones, sistema_general_de_regal_as, recursos_propios, ...	Contexto (regalías = mayor riesgo)
Personas del contrato	nombre_representante_legal, identificaci_n_representante_legal, nombre_supervisor, n_mero_de_documento_supervisor, nombre_ordenador_del_gasto, n_mero_de_documento_ordenador_del_gasto	PII: se seudonimizan
Bancarios	nombre_del_banco, tipo_de_cuenta, n_mero_de_cuenta	Se excluyen (100 % "No definido" en la muestra y sin finalidad legítima)

6. Datos personales detectados (insumo para la clasificación)

Porcentaje de registros con valor real en los campos PII (muestra de 5.000 contratos de Antioquia, 2025–2026):

Campo	% con valor real	Clasificación preliminar
documento_proveedor (81,5 % son cédulas)	99,6 %	PII : seudonimizar cuando tipodocproveedor ≠ NIT
proveedor_adjudicado (nombre)	100 %	PII si es persona natural
nombre_representante_legal	99,9 %	PII
identificaci_n_representante_legal	18,0 %	PII (el resto: "Sin Descripcion")
nombre_supervisor / n_mero_de_documento_supervisor	76,7 %	PII (servidor público)
nombre_ordenador_del_gasto / documento	79,7 %	PII (servidor público)
n_mero_de_cuenta	0,0 %	Excluir

Tensión que el Plan de Gobierno debe resolver: el dato es **público** en la fuente (Ley 1712 de 2014, transparencia), pero la **reutilización** por parte de la contraloría es un nuevo tratamiento, sujeto a la Ley 1581 de 2012 (finalidad, circulación restringida, seguridad). Decisión preliminar: la capa *raw* se conserva íntegra y con acceso restringido para la trazabilidad legal; las capas *curated* y *mart* solo tienen seudónimos (hash con sal). El dashboard nunca muestra una cédula.

Clasificación preliminar de los activos derivados: *raw* = **Confidencial** (contiene PII en claro) · *curated* = **Interno** · *mart* de riesgo = **Confidencial**, porque las alertas previas a una auditoría no deben divulgarse · indicadores agregados = **Público**.

7. Hallazgos iniciales de calidad (se formalizan como reglas en la Entrega 2)

Dimensión	Regla observada	Registros afectados
Compleitud	fecha_de_firma nula (Antioquia, todo el histórico)	40.638
Compleitud	Nulos disfrazados: "No definido", "Sin Descripcion" en campos de personas y bancos	ver §6
Validez	ciudad = 'No Definido' (alcance 2024+)	20.706
Exactitud	valor_del_contrato = 0	2.848
Exactitud	valor_del_contrato > \$100.000 millones (candidatos a error de digitación)	47
Consistencia	fecha_de_fin < fecha_de_inicio	187
Consistencia	Nombres de entidad no normalizados (p. ej. MUNICIPIO DE ENVIGADO*)	por medir
Integridad referencial	Contratos cuyo proceso_de_compra no aparece en DS-02 (en la muestra, 2 de 3 no cruzaron)	por medir

Dimensión	Regla observada	Registros afectados
Unicidad	id_contrato duplicado	0 en la muestra
Oportunidad	Último cargue de DS-01	27-sep-2026 (≤ 24 h) 
Oportunidad (metadato)	ultima_actualizacion vacío; :updated_at se reescribe para todo el dataset cada día	97,8 % vacío / 576.686 registros con la misma marca

8. Estrategia de ingesta (se implementa en la Entrega 2)

- **API SODA** de Socrata: `https://www.datos.gov.co/resource/jbjy-vk9h.json` con filtros SoQL en el servidor.
 - **Paginación:** `$limit=50000 + $offset`, con `$order=:id` para que las páginas sean estables.
 - **Incremental, con un hallazgo que cambia el diseño:** se probaron dos marcas de agua y ninguna sirve.
 - El campo del negocio `ultima_actualizacion` viene vacío en el 97,8 % de los registros.
 - El campo de sistema `:updated_at` sí funciona, pero el publicador **recarga el dataset completo cada día**: 576.686 registros de Antioquia tenían la misma marca (`2026-09-27T03:05:29Z`). Filtrar por `:updated_at` traería todo, siempre.
- Diseño adoptado:** se re-extrae una **ventana móvil** (contratos firmados en los últimos 120 días, más los que no están en estado terminal) y se detectan cambios con un **hash por registro** (`id_contrato` + campos de negocio). Una vez por semana se refresca el alcance completo para conciliar. Este hallazgo va al catálogo como metadato operativo de la fuente.
- **Zonas de almacenamiento:** `raw` (JSON → Parquet, inmutable, particionado por fecha de corte) → `curated` (limpio, tipado, PII seudonimizada) → `mart` (agregados de riesgo).
 - **Linaje:** cada lote registra consulta SoQL, marca de agua, número de filas, hash del archivo y score de calidad.

9. Banderas rojas preliminares (hipótesis para el EDA)

#	Bandera roja	Campos	Pregunta (doc. 01)
BR1	Contratación directa por encima del patrón histórico de la entidad	modalidad_de_contratacion, nombre_entidad, fecha_de_firma	P1
BR2	Firma en ventana pre-Ley de Garantías o en los últimos días de la vigencia	fecha_de_firma, modalidad_de_contratacion	P2
BR3	Concentración proveedor–entidad (% del valor de la entidad)	documento_proveedor, nombre_entidad, valor_del_contrato	P3
BR4	Persona natural con contratos simultáneos en varias entidades	documento_proveedor, fechas de inicio y fin	P4


#	Bandera roja	Campos	Pregunta (doc. 01)
BR5	Valor atípico para su tipo y modalidad (IQR / z-robusto)	valor_del_contrato , tipo_de_contrato	P5
BR6	Proceso competitivo con un solo oferente	DS-02 respuestas_al_procedimiento	P6
BR7	Prórrogas excesivas	dias_adicionados , duración	—
BR8	Fraccionamiento: varios contratos del mismo par entidad-proveedor en pocos días	par + fecha_de_firma + objeto_del_contrato	P3

Las banderas rojas **no son hallazgos**: solo indican qué revisar primero. Así lo dice el principio "la máquina mide, la persona decide".

03 · Procesos (BPMN 2.0)

Proceso	Vigilancia fiscal a la contratación pública
Código / versión	ORCA-PR-001 · AS-IS v1.0 y TO-BE v1.0 · 28-sep-2026
Archivos fuente	bpmn/ORCA-AS-IS-v1.0.bpmn · bpmn/ORCA-TO-BE-v1.0.bpmn
Herramienta	BPMN 2.0 XML estándar con diagrama (DI). Se abre en demo.bpmn.io , Camunda Modeler o draw.io. Validado con bpmn-js: 0 advertencias
Criterio de rúbrica	2. Procesos (BPMN) con mejoras identificadas (10 %)

1. AS-IS: cómo se selecciona hoy qué contratos vigilar



Participantes. Un pool con carriles (la contraloría) y dos pools de **caja negra**: la entidad sujeta de control y el portal SECOP II. Se modelan como caja negra porque la contraloría no controla su comportamiento interno; solo intercambia mensajes con ellos.

Carril	Rol
Dirección de Planeación / Contralor Auxiliar	Planea la vigencia y valida el informe
Equipo Auditor	Busca, depura, selecciona y revisa
Oficina TIC (soporte)	Extrae bases cuando el volumen supera lo que el portal permite consultar

Recorrido. Un temporizador anual (inicio de vigencia) dispara la elaboración del Plan de Vigilancia (PVCF) por criterio histórico. El auditor busca contratos manualmente en el portal. Si el volumen no es manejable, le pide una extracción a TIC, que envía archivos Excel sin control de versiones. El auditor consolida y depura a mano, elige una muestra por juicio experto y pide soportes a la entidad. Una **compuerta basada en eventos** espera la respuesta (mensaje) o el vencimiento de 10 días hábiles, y en ese caso se reitera la solicitud. Finalmente revisa la muestra y, si hay presuntos hallazgos, se valida y comunica el informe.

Dolores identificados (en rojo en el diagrama)

#	Dolor	Tipo de desperdicio	Impacto en el dato
D1	Planeación por histórico y criterio, no por riesgo medible	Decisión sin evidencia	La selección no se puede explicar ni auditar
D2	Búsqueda manual en el portal, sin API	Tiempo, reproceso	Sin linaje: nadie sabe qué se consultó ni cuándo
D3	Dependencia de TIC para extracciones ad hoc	Espera	Nadie es dueño del dato; versiones distintas del mismo contrato
D4	Depuración en Excel sin reglas de calidad	Reproceso, error	Calidad no medida; PII copiada sin control (riesgo Ley 1581)
D5	Muestra por juicio experto	Baja cobertura	Sesgo; patrones como el pico pre-Ley de Garantías pasan inadvertidos
D6	Esperas sin SLA y reiteraciones manuales	Espera	Actuaciones tardías: el dinero ya se gastó
D7	El resultado no retroalimenta la selección	Aprendizaje perdido	La siguiente vigencia se planea igual

2. TO-BE: ORCA, priorización de la vigilancia basada en riesgo

Entidad sujeta de control fiscal (caja negra)

Contratador Auxiliar: Datos Owner
Leyenda: Azul = tarea automatizada (AUTO) - Morado = decisión de gobierno del dato - Verde = mejora frente al ASIS (ver 03_procesos_bpmn.mxd, tabla de mejoras)

Consumidor: Datos Auditor
Gestión por excepción: el auditor ya no busca contratos. Solo recibe alertas de riesgo alto, priorizadas y con el enlace al proceso en SECOP II.


Contratador Auxiliar: Datos Owner
Consumidor: Datos Auditor
Gestión por excepción: el auditor ya no busca contratos. Solo recibe alertas de riesgo alto, priorizadas y con el enlace al proceso en SECOP II.

Contratador Auxiliar: Datos Owner
Consumidor: Datos Auditor
Gestión por excepción: el auditor ya no busca contratos. Solo recibe alertas de riesgo alto, priorizadas y con el enlace al proceso en SECOP II.

datos.gov.co: SECOP II Contratos (day-vtkn) y Procesos (p6di-6zbt) API SODA (caja negra)

Sub-proceso "Validar calidad del lote (6 dimensiones)" (colapsado en el diagrama principal; en el modelador se abre con doble clic):

BPMN.IO



2.1 Carriles: cada tarea vive en el carril de quien la ejecuta

Carril	Rol del Data Office (ver doc. 01)	Qué hace en el proceso
Contralor Auxiliar · Data Owner	Rinde cuentas por el dato y por la decisión	Prioriza el sujeto y decide la actuación fiscal

Carril	Rol del Data Office (ver doc. 01)	Qué hace en el proceso
Equipo Auditor · Consumidor	Usa el dato	Analiza alertas y dice si son pertinentes
Data Steward · Gobierno del dato	Custodia de negocio	Decide sobre los lotes con baja calidad; recalibra las reglas con los falsos positivos
Ingeniería de Datos · Custodio técnico	Opera el pipeline	Diagnostica fallos de extracción
Plataforma ORCA [AUTO]	Automatización	Todo lo determinista y repetible

Aislar la plataforma en su propio carril deja ver de un vistazo que **la mayor parte del proceso ya no es trabajo humano**. Los carriles humanos quedan casi vacíos a la izquierda porque las personas solo intervienen **por excepción**.

2.2 Recorrido normal

1. **Temporizador diario (02:00)** → extracción del lote desde la API SODA (tarea de servicio). La interacción con datos.gov.co se modela con **flujos de mensaje** (consulta SoQL → lote JSON).
2. **Compuerta paralela (AND)**: en paralelo y de forma **obligatoria**, se registran los metadatos y el linaje del lote (se escribe en el almacén *Catálogo de datos y linaje*) y se valida la calidad (sub-proceso). Con un XOR se podría perder el linaje, y con un OR la trazabilidad sería opcional. El AND de unión exige que ambas ramas terminen.
3. **Quality gate (XOR)**: con un score $\geq 95\%$, el lote sigue solo. Con menos, lo revisa el Data Steward.
4. **Seudonimizar PII y aplicar clasificación** → objeto de datos *Dataset curado (PII seudonimizada)*, que entra a:
5. **Calcular banderas rojas y score de riesgo** (tarea de **regla de negocio**: aplica reglas versionadas, no es un servicio genérico).
6. **Publicar el data mart y refrescar el dashboard** → almacén *Data mart ORCA*.
7. **¿Hay contratos con riesgo alto?** No → fin *Monitoreo diario completado*. Sí → **tarea de envío**: notificar alertas priorizadas al auditor (el candidato a automatizar con Power Automate en la entrega 2).
8. El auditor **analiza la alerta** con la evidencia enlazada al SECOP. Si es pertinente, el Data Owner **prioriza y define la actuación**. Una **compuerta inclusiva (OR)** permite emitir una alerta temprana a la entidad, incluirla en el PVCF, **o ambas**; por defecto, se incluye en el PVCF. El OR de unión espera solo las ramas activadas.

2.3 Excepciones y SLA: tres mecanismos, deliberadamente distintos

Situación	Mecanismo BPMN	Comportamiento
Falla técnica (API caída o esquema cambiado)	Evento de error adjunto (interruptor) a la extracción	Ingeniería diagnóstica. Si quedan intentos (< 3), un temporizador intermedio de 1 h (backoff) devuelve el token a la compuerta de convergencia anterior a la extracción. Agotados los intentos → fin de terminación (cancela toda la instancia; ningún token queda colgado).

Situación	Mecanismo BPMN	Comportamiento
Calidad insuficiente (score < 95 %)	Compuerta XOR (no un evento de error: es un incumplimiento de contrato, no una falla de sistema)	El Steward decide si libera el lote con advertencia o lo deja en cuarentena . El flujo por defecto es la revisión: ante la duda, no se publica.
Inacción humana (alerta sin gestión)	Temporizador adjunto no interruptor (P3D) en "Analizar alerta"	A los 3 días hábiles se lanza un evento de fin de escalamiento al Contralor Auxiliar, sin cancelar la tarea del auditor.

2.4 Estados finales

#	Estado final	Carril	Significado
F1	Monitoreo diario completado	Plataforma	Lote procesado, sin riesgos altos
F2	Actuación fiscal programada	Data Owner	Éxito: alerta convertida en actuación
F3	Alerta descartada (retroalimenta el modelo)	Steward	Falso positivo registrado para recalibrar las reglas
F4	Lote en cuarentena	Steward	El dato no se publica
F5	Extracción fallida: incidente escalado	Ingeniería	Terminación: fallo no recuperable
F6	Alerta escalada al Contralor Auxiliar	Data Owner	Escalamiento por SLA vencido

3. Mejoras: del AS-IS al TO-BE

Mejora	Resuelve	Qué cambia	Indicador
M1 Ingesta diaria automatizada por API	D2, D3	Temporizador + tarea de servicio; linaje por lote	Frescura $\leq$ 24 h; 0 extracciones manuales
M2 Quality gate con gestión por excepción	D4	Sub-proceso de 6 dimensiones + umbral del 95 %; el Steward solo ve los lotes que fallan	Score de calidad por lote; % de lotes en cuarentena
M3 Seudonimización y clasificación de PII	D4	La PII se transforma antes de cualquier consumo (Ley 1581)	0 PII en claro en las capas de consumo
M4 Selección por riesgo	D1, D5	Banderas rojas ponderadas reemplazan el juicio experto como primer filtro	100 % de cobertura con score
M5 Alertas con SLA y escalamiento	D6	Notificación automática + temporizador P3D	% de alertas gestionadas dentro del SLA
M6 Ciclo de retroalimentación	D7	Los falsos positivos recalibran las reglas versionadas	Precisión de alertas (pertinentes / gestionadas)

Frontera manual / automático. Se automatiza lo **determinista, repetible y sin juicio de valor**: extraer, registrar el linaje, medir la calidad, seudonimizar, calcular el score, publicar y notificar. Queda humano lo que exige **criterio o rendición de cuentas**: liberar un lote defectuoso, decidir si una alerta es pertinente y elegir la actuación fiscal. **La máquina mide, la persona decide.**

Candidatos para la automatización de la entrega 2 (criterio 3 de la rúbrica):

- 1. Ingesta programada (script de Python + Programador de tareas de Windows o GitHub Actions): tareas M1 y T1.
- 2. Notificación de alertas por correo con Power Automate, leyendo el data mart: tarea M5 "Notificar alertas".


4. Notación utilizada

Elemento	Dónde
Pools de caja negra + flujos de mensaje	Entidad sujeta de control; SECOP II / datos.gov.co
Carriles (5 en el TO-BE, 3 en el AS-IS)	Un carril por rol
Eventos de inicio temporizados	Anual (AS-IS) y diario (TO-BE)
Tareas de usuario, servicio, regla de negocio y envío	Según quién o qué ejecuta la tarea
Sub-proceso con su propio plano	Validar calidad del lote
Compuertas XOR (con flujo por defecto), AND, OR y basada en eventos	Decisiones, paralelismo obligatorio, actuaciones combinables, espera de respuesta
Evento de error adjunto (interruptor)	Fallo de la API
Temporizador adjunto no interruptor	SLA de la alerta
Temporizadores intermedios	Backoff de 1 h; 10 días hábiles (AS-IS)
Evento de mensaje intermedio	Soportes recibidos (AS-IS)
Fin de terminación y fin de escalamiento	Fallo no recuperable; SLA vencido
Objetos de datos y almacenes de datos	Lote crudo, informe de calidad, dataset curado; catálogo, data mart, reglas versionadas
Anotaciones	Dolores D1–D7 y mejoras M1–M6
Color	Rojo = dolor (AS-IS) · Azul = automatizado · Morado = decisión de gobierno

04 · Arquitectura de la solución (ArchiMate) · Boceto

Modelo	archimate/ORCA-Arquitectura-v0.1.archimate (formato nativo de Archi)
Versión	v0.1, boceto de la Entrega 1 · 28-sep-2026
Contenido	77 elementos · 95 relaciones · 3 vistas
Validación	Todas las relaciones se verificaron contra la tabla oficial de relaciones permitidas de Archi 5.10 (ArchiMate 3.2). Las imágenes se exportaron con Archi.
Criterio de rúbrica	4. Arquitectura de datos: modelo de las 3 capas coherente y justificado (10 %)

Vista 01 · Por capas (negocio · aplicación · tecnología)



Capa de negocio. Los procesos son los mismos del BPMN TO-BE, con el mismo lenguaje: *Monitorear la contratación* → *Analizar y validar alertas* → *Programar la actuación fiscal* (relaciones de *disparo*), más el proceso de apoyo *Gobernar los datos de contratación*, asignado al Data Steward y al CDO. Cada actor se asigna al

proceso que ejecuta, igual que los carriles del BPMN. El proceso de monitoreo realiza el servicio *Alertas tempranas*, que sirve al auditor. La actuación fiscal realiza la *Vigilancia fiscal preventiva*, que sirve a la entidad sujeta de control.


Capa de aplicación. Cada servicio de aplicación lo realiza un componente con una sola responsabilidad:

Componente	Servicio que realiza	Proceso de negocio al que sirve
Pipeline ORCA (Python)	Ingesta incremental	Monitorear
Motor de reglas de riesgo	Scoring de riesgo	Monitorear
Dashboard ORCA + Notificador (Power Automate)	Visualización y alertas	Analizar alertas
Motor de calidad	Validación de calidad	Gobernar datos
Módulo de privacidad	Seudonimización y clasificación	Gobernar datos
Catálogo de datos y linaje	Catálogo y linaje	Gobernar datos

SECOP II / datos.gov.co aparece como **componente externo** que expone la **interfaz API SODA**. La contraloría **consume** datos de SECOP y **nunca escribe** en él.

Capa de tecnología. Un *Servidor de analítica ORCA* (Python 3.13, pandas, Jupyter y un programador de tareas) realiza el almacenamiento de archivos (Parquet por zonas) y la programación de tareas. GitHub realiza el control de versiones y un servicio de BI (Power BI o Streamlit) publica el dashboard. Todo se conecta por Internet (HTTPS) a la plataforma Socrata de datos.gov.co.

Vista 02 · Motivación y estrategia




Esta vista es la **trazabilidad del porqué**: una cada decisión de arquitectura con la estrategia del documento 01.

- **Drivers medidos en los datos, no supuestos:** 302.507 contratos, 85,5 % por contratación directa, el pico de 49.906 contratos en enero de 2026 y el marco normativo.
- **Evaluaciones** → **metas** → **resultados** medibles (≥ 95 % de calidad, 0 PII en claro, 100 % de los contratos con score en ≤ 24 h).
- Los **principios** (calidad antes de publicar, privacidad desde el diseño, la máquina mide y la persona decide) influyen en los resultados.
- Los **requisitos** los realizan componentes concretos de la capa de aplicación. Así, cada componente de la vista 01 existe porque responde a un requisito.

- **Estrategia:** el curso de acción *Crear un Data Office híbrido (hub & spoke)* realiza la meta de datos gobernados. La capacidad *Analítica de riesgo en contratación* realiza la meta de priorizar por riesgo.

Vista 03 · Flujo de información (boceto de linaje)



Esta vista es el primer boceto del **linaje** exigido por el gobierno de datos (fuente → transformación → dataset → dashboard). Las relaciones de *flujo* etiquetadas muestran el lote atravesando pipeline → calidad → privacidad → reglas de riesgo → dashboard y notificador. Cada objeto de datos está realizado por un artefacto físico de su zona (*raw*, *curated*, *mart*). En la entrega 2 se completa con el catálogo y el linaje a nivel de campo.

Decisiones de arquitectura (justificación)

#	Decisión	Alternativa descartada	Por qué
AD-1	Ingesta por API SODA con ventana móvil y hash por registro	Descargar el CSV completo (6 M de filas) cada día	Solo se trae el alcance (Antioquia). La marca de agua <code>:updated_at</code> no sirve porque el publicador reescribe todo a diario (ver doc. 02).
AD-2	Almacenamiento en Parquet por zonas (raw → curated → mart)	Una única tabla o archivos Excel	Zonas = linaje y control de acceso por nivel de sensibilidad. <i>raw</i> es inmutable (evidencia legal). Parquet es columnar, tipado y comprimido.
AD-3	Módulo de privacidad separado del pipeline	Seudonimizar "donde toque" dentro del notebook	Un único punto de control para la PII, fácil de auditar por el Oficial de Protección de Datos
AD-4	Motor de reglas de riesgo con reglas versionadas	Umbrales fijos dentro del código	El Steward recalibra sin reescribir el pipeline (mejora M6); cada score queda asociado a la versión de las reglas
AD-5	Local + GitHub , sin nube	AWS/Azure/GCP	La nube es opcional en el curso y no agrega valor para un volumen de ≈ 300 mil filas. La arquitectura queda preparada: las zonas se mapean 1:1 a un lago de datos en la nube si se escala.
AD-6	Notificador en Power Automate	Correo desde Python	Es la herramienta de automatización vista en el curso y lo que usaría una entidad pública con Microsoft 365

Pendiente para las siguientes entregas

- **Entrega 2:** vista de linaje a nivel de campo, vista de seguridad y control de acceso (quién accede a cada zona) y un artefacto real por cada zona.
- **Entrega final:** vista de despliegue definitiva y alineación con el dashboard implementado.

Cómo abrir el modelo

1. Descargar **Archi** (gratuito): <https://www.archimatetool.com/download/>
2. *File* → *Open* → `documentacion/archimate/ORCA-Arquitectura-v0.1.archimate`
3. Las 3 vistas están en la carpeta *Views*. Cada elemento tiene documentación en la pestaña *Properties*.